

Rapport TP 1: Analyse Statistique Descriptive (Jeu de données Iris)

Michel TCHATCHOUA, IADS 3

28 octobre 2025

Table des matières

1	Introduction et Données	2
2	Analyse Monodimensionnelle	2
2.1	Calcul des Statistiques Globales	2
2.2	Commentaires et Intuition (Classification Monodimensionnelle)	2
3	Analyse Conditionnelle	3
3.1	Statistiques Conditionnelles (Intra-Classe)	3
3.2	Calcul des Variances Inter-Classes	3
3.3	Graphe pour chaque descripteur	4
3.4	Commentaires et Conclusion (Classification Monodimensionnelle)	4
4	Analyse Bidimensionnelle et GMM	5
4.1	Paire de descripteurs ($d1 = 1, d2 = 2$)	5
4.2	Paire de descripteurs ($d1 = 2, d2 = 4$)	6
4.3	Conclusion sur la Paire de Descripteurs	6
5	Vérification de l'Intuition (Classifieur Plus Proche Voisin)	7
5.1	Séparation des Données	7
5.2	Performances du Classifieur (<i>NearestNeighbors</i>)	7

1 Introduction et Données

Ce rapport présente l'analyse descriptive et conditionnelle du jeu de données classique `iris` de `scikit-learn`, conformément aux directives du TP.

La matrice d'observations $\mathbf{X}$ et le vecteur de labels $\mathbf{y}$ ont été définis :

- **Nombre d'exemples** (*observations*): 150
- **Nombre de descripteurs** (*caractéristiques*): 4
 - d_1 : Longueur du sépale,
 - d_2 : Largeur du sépale,
 - d_3 : Longueur du pétale,
 - d_4 : Largeur du pétale.
- **Nombre de classes** (*labels*): 3
 - Setosa,
 - Versicolor,
 - Virginica.

En gros, le jeu de données Iris est un classique du machine learning. Chaque fleur est décrite par 4 mesures morphologiques et appartient à l'une des 3 espèces d'iris.

2 Analyse Monodimensionnelle

2.1 Calcul des Statistiques Globales

Le tableau suivant résume la moyenne μ et la variance σ^2 pour chacun des quatre descripteurs sur l'ensemble des données. Les valeurs sont arrondies à deux décimales.

Table 1: Moyenne et Variance globales des descripteurs Iris

Descripteur	Moyenne μ	Variance σ^2
d_1 (Long. Sépale)	5.84	0.69
d_2 (Larg. Sépale)	3.06	0.19
d_3 (Long. Pétale)	3.76	3.10
d_4 (Larg. Pétale)	1.20	0.58

2.2 Commentaires et Intuition (Classification Monodimensionnelle)

Pour la classification, la variance globale seule n'est pas l'indicateur le plus pertinent. Cependant, en observant la distribution des données :

- Le descripteur d_3 (Longueur du Pétale) possède la **plus grande variance** (3.10). Une grande variance suggère que les valeurs sont très étalées, ce qui pourrait indiquer une bonne séparation des classes si cette variance est principalement due aux différences entre les classes (*variance inter-classe*).
- Le descripteur d_2 (Largeur du Sépale) a la **plus petite variance** (0.19). Une faible variance suggère que les valeurs sont très regroupées, ce qui pourrait rendre la séparation des classes difficile (*chevauchement*).

Intuitivement, le **meilleur descripteur** pourrait être d_3 (haute variance), et le **moins bon** d_2 (basse variance).

3 Analyse Conditionnelle

3.1 Statistiques Conditionnelles (Intra-Classe)

Soit $\bar{X}^{(h)}$ la moyenne de la classe h et $V^{(h)}$ sa variance. Les résultats par classe (arrondis à deux décimales) sont dans le Tableau 2 suivant :

Table 2: Moyennes $\bar{X}^{(h)}$ et Variances $V^{(h)}$ conditionnelles (Intra-classe)						
Descripteur	Setosa ($h = 1$)		Versicolor ($h = 2$)		Virginica ($h = 3$)	
	$\bar{X}^{(1)}$	$V^{(1)}$	$\bar{X}^{(2)}$	$V^{(2)}$	$\bar{X}^{(3)}$	$V^{(3)}$
d_1 (Long. Sépale)	5.01	0.12	5.94	0.27	6.59	0.40
d_2 (Larg. Sépale)	3.43	0.14	2.77	0.10	2.97	0.10
d_3 (Long. Pétale)	1.46	0.03	4.26	0.22	5.55	0.30
d_4 (Larg. Pétale)	0.25	0.01	1.33	0.06	2.03	0.06

3.2 Calcul des Variances Inter-Classes

Le théorème de la variance totale (Konig-Huygens) stipule que la variance totale V_{totale} est la somme de la variance intra-classe V_{intra} (moyenne des variances) et de la variance inter-classe V_{inter} :

$$V_{totale} = V_{intra} + V_{inter}$$

Où $V_{intra} = \sum_{h=1}^k \frac{n_h}{n} V^{(h)}$ et $V_{inter} = \sum_{h=1}^k \frac{n_h}{n} (\bar{X}^{(h)} - \bar{X})^2$.

En utilisant les valeurs globales de V_{totale} et en calculant V_{intra} à partir du Tableau 2 (avec $n_h = 50$ pour chaque classe) :

$$V_{intra} = \frac{1}{3} \sum_{h=1}^3 V^{(h)}$$

Nous pouvons déduire $V_{inter} = V_{totale} - V_{intra}$.

Table 3: Variances Inter-classes V_{inter} des descripteurs			
Descripteur	V_{totale}	V_{intra}	$V_{inter} = V_{totale} - V_{intra}$
d_1 (Long. Sépale)	0.69	0.26	0.42
d_2 (Larg. Sépale)	0.19	0.11	0.07
d_3 (Long. Pétale)	3.11	0.18	2.91
d_4 (Larg. Pétale)	0.58	0.04	0.54

3.3 Graphe pour chaque descripteur




Figure 1: Valeurs des classes en fonction des descripteurs.

3.4 Commentaires et Conclusion (Classification Monodimensionnelle)

Dans les graphiques, on observe :

- **Petal length** et **Petal width** : séparation nette des trois classes (peu de chevauchement).
- **Sepal width** : forte superposition entre *Versicolor* et *Virginica*.
- **Setosa** est généralement bien séparée sur tous les descripteurs.

Afin de confirmer ces observations, faisons un tableau pour évaluer le pouvoir discriminant :

Table 4: Pouvoir discriminant des descripteurs ($\text{Var}_{\text{inter}}/\text{Var}_{\text{totale}}$)

Descripteur	Var inter	Var totale	Ratio (%)
sepal length (cm)	0.416	0.681	61.092
sepal width (cm)	0.073	0.189	38.855
petal length (cm)	2.910	3.096	94.018
petal width (cm)	0.535	0.577	92.743

Pour une bonne classification, on recherche un **grand ratio** (les classes sont très séparées et peu dispersées en interne). On a alors :

MEILLEUR descripteur : Petal length (d3)

- Ratio inter-classe très élevée (94%)
- Les moyennes des 3 classes sont très différentes (1.46, 4.26, 5.55)

- Faible chevauchement entre les classes
- Setosa est complètement séparée des deux autres
- Bon pouvoir de séparation même entre Versicolor et Virginica

Deuxième meilleur : Petal width (d4)

- Ratio inter-classe 93%
- Excellente séparation des classes
- Pattern similaire à Petal length

MOINS BON descripteur : Sepal width (d2)

- Ratio inter-classe faible (40%)
- Chevauchement important entre Versicolor et Virginica
- Les moyennes des classes sont proches
- Difficile de discriminer les classes avec ce seul descripteur

4 Analyse Bidimensionnelle et GMM

4.1 Paire de descripteurs ($d1 = 1, d2 = 2$)





Figure 2: Visualisation des données plan ($d1, d2$).

Figure 3: Contours de densité ($d1=1, d2=2$).

L'observation du nuage de points ($d1, d2$) montre que :

- La classe Setosa est clairement séparée des deux autres.
- Les classes Versicolor et Virginica se chevauchent de manière significative dans ce plan, en formant un nuage légèrement étiré le long d'une diagonale.

L'estimation des densités de probabilité conditionnelles (via `sklearn.mixture.GaussianMixture` avec $n_{\text{components}} = 1$ par classe) permet de visualiser les ellipses de confiance (Figures 3).

Les matrices de covariance conditionnelles (elles décrivent la forme et l'orientation des nuages de points de chaque classe) montrent pour les classes chevauchantes (Versicolor/Virginica) que les nuages de points sont étirés dans une direction oblique (covariance non nulle).

4.2 Paire de descripteurs ($d1 = 2, d2 = 4$)




Figure 4: Contours de densité ($d1 = 2, d2 = 4$).

L'observation du nuage de points ($d1 = 2, d2 = 4$) montre :

- La classe Setosa est parfaitement séparée.
- Les classes Versicolor et Virginica sont nettement mieux séparées que dans le plan ($d1, d2$), avec une ligne de séparation beaucoup plus nette et un chevauchement minimal.

4.3 Conclusion sur la Paire de Descripteurs

L'analyse visuelle et l'analyse conditionnelle confirment que la **paire de descripteurs** ($d1 = 2, d2 = 4$) est la **plus adaptée** pour faire de la classification. La séparation entre les trois classes est maximale dans ce plan.

5 Vérification de l'Intuition (Classifieur Plus Proche Voisin)

5.1 Séparation des Données

Les données ont été séparées en jeux de référence (80%) et de test (20%) en utilisant `train_test_split` avec `random_state=1`.

5.2 Performances du Classifieur (*NearestNeighbors*)

Le classifieur Plus Proche Voisin a été entraîné sur l'ensemble de référence et évalué sur l'ensemble de test. Le choix de la paire de descripteurs a un impact direct sur la performance.

Table 5: Performance du Classifieur Plus Proche Voisin (Précision)

Paire de Descripteurs	Précision (Accuracy)	Statut
$(d1 = 1, d2 = 2)$	$\sim 73\%$	Moins optimal
$(d1 = 2, d2 = 4)$	$\sim 97\%$	Optimal

Les résultats de l'évaluation confirment l'intuition :

- La paire $(d1 = 2, d2 = 4)$ permet d'atteindre une précision parfaite (97%) sur l'ensemble de test, prouvant sa forte capacité discriminante.
- La paire $(d1 = 1, d2 = 2)$ obtient un bon score (73%), mais est moins performante en raison du chevauchement des classes Versicolor et Virginica dans ce plan.